

# PRML 解答集

2022 年 4 月 17 日

## 問題 3.3

それぞれのデータ点  $t_n$  に重み要素  $r_n > 0$  が割り当てられており，二乗和誤差関数が

$$E_D(w) = \frac{1}{2} \sum_{n=1}^N r_n \{t_n - w^T \phi(x_n)\}^2 \quad (3.104)$$

となるデータ集合を考える．このとき，この誤差関数を最小にする解  $w^*$  についての式を求めよ．また，(i) ノイズの分散がデータに依存する場合，(ii) データ点に重複がある場合に照らして，それぞれ重み付き二乗和誤差関数の解釈を与えよ．

## 方針 3.3

## 解答 3.3

$\phi = (\phi(x_1), \phi(x_2), \dots, \phi(x_n))^T$ ,  $D = \text{diag}(r_1, \dots, r_n)$  とすると

$$E_D(w) = \frac{1}{2} (t - \phi w)^T D (t - \phi w)$$

と表せる．上式を  $w$  で微分すると

$$\begin{aligned} \frac{\partial}{\partial w} E_D(w) &= \frac{\partial}{\partial w} \left\{ \frac{1}{2} (t^T - w^T \phi^T) D (t - \phi w) \right\} \\ &= \frac{\partial}{\partial w} \left\{ \frac{1}{2} (t^T D t - t^T D \phi w - w^T \phi^T D t + w^T \phi^T D \phi w) \right\} \\ &= \phi^T D \phi w - \phi^T D t \end{aligned}$$

なお，ここでは以下の微分公式を利用．

$$\frac{\partial}{\partial x} (x^T a) = \frac{\partial}{\partial x} (a^T x) = a \quad (C.19)$$

$$\frac{\partial}{\partial x} (x^T A x) = 2 A x (A \text{ は対角行列})$$

$\frac{\partial}{\partial w} E_D(w) = 0$  を満たす  $w$  が誤差関数を最小にする  $w^*$  であり，計算すると

$$\mathbf{w}^* = (\phi^T D \phi)^{-1} \phi^T D \mathbf{t}$$

となる。

誤差関数の解釈

(i) ノイズの分散がデータに依存する場合

(3.10) にて、右辺の  $\beta$  が  $n$  に依存しているということなので、

$$P(\mathbf{t}|\mathbf{x}, \mathbf{w}, \beta) = \prod_{n=1}^N N(t_n | \mathbf{w}^T \phi(\mathbf{x}_n), \beta_n^{-1})$$

$$\begin{aligned} \log P(\mathbf{t}|\mathbf{x}, \mathbf{w}, \beta) &= \sum_{n=1}^N \log \exp \left\{ -\frac{1}{2} \beta_n (t_n - \mathbf{w}^T \phi(\mathbf{x}_n))^2 \right\} + (w \text{ に依らない項}) \\ &= \frac{1}{2} \sum_{n=1}^N \beta_n (t_n - \mathbf{w}^T \phi(\mathbf{x}_n))^2 + \text{const} \end{aligned}$$

となり、(3.104) の誤差関数が出現する。

(ii) データ点の重複がある場合

(3.104) の式の形から、ある  $n$  についてのデータ  $(t_n, \mathbf{x}_n)$  が  $r_n$  個ずつある時の二乗和誤差を表していることが分かる。

問題 3.6

ガウス分布に従う複数の目標変数  $t$  を持つ次の形の線形基底関数モデルを考える。

$$p(t|\mathbf{W}, \Sigma) = N(t|\mathbf{x}, \mathbf{W}, \Sigma) \quad (3.107)$$

ただし,

$$y(\mathbf{x}, \mathbf{W}) = \mathbf{W}^T \phi(\mathbf{x}) \quad (3.108)$$

である。入力基底ベクトル  $\phi(\mathbf{x}_n)$  ( $n = 1, \dots, N$ ) とそれに対応する目標ベクトル  $t_n$  が訓練データ集合として与えられるとき, パラメータ行列  $\mathbf{W}$  の最尤推定解  $\mathbf{W}_{ML}$  のそれぞれの列が, 等方性のノイズ分布に対する解の (3.15) の形の式で与えられることを示せ。これは共分散行列  $\Sigma$  にはよらないことに注意せよ。さらに,  $\Sigma$  の最尤指定解が

$$\Sigma = \frac{1}{N} \sum_{n=1}^N (t_n - \mathbf{W}_{ML} \phi(\mathbf{x}_n))(t_n - \mathbf{W}_{ML} \phi(\mathbf{x}_n))^T \quad (3.109)$$

で与えられることを示せ。

方針 3.6

解答 3.6

$X$ : 入力ベクトル  $x_1, \dots, x_n$  を並べた行列

とする。対数尤度関数は

$$\begin{aligned} \ln P(T|X, W, \Sigma) &= \sum_{n=1}^N \ln N(t_n | \mathbf{W}^T \phi(\mathbf{x}_n), \Sigma) \\ &= -\frac{NK}{2} \ln(2\pi) - \frac{N}{2} \ln |\Sigma| - \frac{1}{2} \sum_{n=1}^N (t_n - \mathbf{W}^T \phi_n)^T \Sigma^{-1} (t_n - \mathbf{W}^T \phi_n) \end{aligned}$$

となる。

$$\frac{\partial}{\partial X} (Xb + c)^T D (Xb + c) = (D + D^T)(Xb + c)b^T$$

ここで,  $T$  を  $n$  番目の行が  $t_n^T$  となる  $N \times K$  行列とし, 上記の公式を用いて  $W^T$  に関する微分計算をすると

$$\frac{\partial}{\partial W^T} \ln P(T|X, W, \Sigma) = \sum_{n=1}^N \Sigma^{-1} (t_n - \mathbf{W}^T \phi_n) \phi_n^T$$

これを  $\mathbf{0}$  とおくと,

$$\begin{aligned} \sum_{n=1}^N \Sigma^{-1}(t_n - w^T \phi_n) \phi_n^T &= \mathbf{0} \\ \Leftrightarrow W^T \sum_{n=1}^N \phi_n \phi_n^T &= \sum_{n=1}^N t_n \phi_n^T \\ &\Leftrightarrow W^T \Phi^T \Phi = T^T \Phi \end{aligned}$$

よって,

$$\begin{aligned} W_{ML}^T &= T^T \Phi (\Phi^T \Phi)^{-1} \\ W_{ML} &= (\Phi^T \Phi)^{-1} \Phi^T T \end{aligned}$$

となり,  $T$  は  $n$  番目の行が  $t_n^T$  となるようにした行列であるから,  $W_{ML}$  のそれぞれの列が, 等方性のノイズ分布に対する解の (3.15) の形の式で与えられることが分かる.

また  $\Sigma$  の最尤解は, 対数尤度関数を  $\Sigma$  で微分して  $\mathbf{0}$  と置き,  $\Sigma$  について解くことで求まる.

これは演習 2.34(以前解いたもの) と全く同手順であるため省略する.

問題 3.7

$m_N$  と  $S_N$  がそれぞれ (3.50) と (3.51) で定義される線形基底関数モデルを考える．平方完成を用いて，このモデルパラメータ  $w$  の事後分布が (3.49) で与えられることを確かめよ．

方針 3.7

解答 3.7

ベイズの公式から

$$p(w|t) \propto p(t|w)p(w)$$

(3.10),(3.48) より,

$$\begin{aligned} & \propto \left( \prod_{n=1}^N \exp \left[ -\frac{1}{2} \{t_n - w^T \phi(x_n)\}^2 \beta \right] \right) \exp \left[ -\frac{1}{2} (w - m_0)^T S_0^{-1} (w - m_0) \right] \\ & = \exp \left[ -\frac{1}{2} \left\{ \beta \sum_{n=1}^N (t_n - w^T \phi(x_n))^2 + (w - m_0)^T S_0^{-1} (w - m_0) \right\} \right] \end{aligned}$$

以下では  $\exp$  の中の  $-\frac{1}{2}$  の中身を見ていく．

$$= \beta \begin{pmatrix} t_1 - w^T \phi(x_1) \\ \vdots \\ t_N - w^T \phi(x_N) \end{pmatrix}^T \begin{pmatrix} t_1 - w^T \phi(x_1) \\ \vdots \\ t_N - w^T \phi(x_N) \end{pmatrix} + (w - m_0)^T S_0^{-1} (w - m_0)$$

$w^T \phi(x_1) = \phi^T(x_1)w$  なので

$$= \beta \begin{pmatrix} t_1 - \phi^T(x_1)w \\ \vdots \\ t_N - \phi^T(x_N)w \end{pmatrix}^T \begin{pmatrix} t_1 - \phi^T(x_1)w \\ \vdots \\ t_N - \phi^T(x_N)w \end{pmatrix} + (w - m_0)^T S_0^{-1} (w - m_0)$$

ここで,

$$\Phi = \begin{pmatrix} \phi^T(x_1) \\ \vdots \\ \phi^T(x_N) \end{pmatrix}$$

であるので, 定数項を  $C$  とおくとして

$$\begin{aligned} & = \beta (t - \Phi w)^T (t - \Phi w) + (w - m_0)^T S_0^{-1} (w - m_0) \\ & = \beta (w^T \Phi^T \Phi w - w^T \Phi^T t - t^T \Phi w) + w^T S_0^{-1} w - w^T S_0^{-1} m_0 - m_0^T S_0^{-1} w + C \end{aligned}$$

$S_0$  は共分散なので対称行列となる．よってその逆行列も対称行列なので  $(S_0^{-1})^T = S_0^{-1}$ ．

$$= w^T(S_0^{-1} + \beta\Phi^T\Phi)w - w^T(S_0^{-1}m_0 + \beta\Phi^T t) - (S_0^{-1}m_0 + \beta\Phi^T t)^T w + C$$

ここで,  $m_N, S_N$  はそれぞれ以下のように与えられている.

$$\begin{aligned} m_N &= S_N(S_0^{-1}m_0 + \beta\Phi^T t) = S_N R \\ S_N^{-1} &= S_0^{-1} + \beta\Phi^T\Phi \end{aligned}$$

これらを用いて平方完成すると

$$\begin{aligned} &= w^T S_N^{-1} w - w^T S_N^{-1} m_N - S_N^{-1} m_N w + C \\ &= (w - m_N)^T S^{-1} (w - m_N) + C' \end{aligned}$$

なおパラメータ  $w$  に依存しない部分を新たに定数  $C'$  と置いた.

以上より,  $C$  を定数として

$$p(w|t) \propto C \exp\{(w - m_N)^T S^{-1} (w - m_N)\}$$

と表せるので, モデルパラメータ  $w$  の事後分布が (3.49) で与えられることが分かる.

問題 3.10

(2.115) の結果を用いて (3.57) の積分を評価し, ベイズ線形回帰モデルの予測分布が (3.58) で与えられることを確かめよ. ただし, 入力に依存する分散は (3.59) で与えられる.

方針 3.10

解答 3.10

(3.57) の条件付き分布と事後分布は, それぞれ以下の式で表される.

$$p(t | \mathbf{w}, \beta) = \mathcal{N}(t | \mathbf{w}^T \phi(\mathbf{x}), \beta^{-1}) \quad (3.3, 3.8)$$

$$p(\mathbf{w} | \mathbf{t}, \alpha, \beta) = \mathcal{N}(\mathbf{w} | \mathbf{m}_N, \mathbf{S}_N) \quad (3.49)$$

ここで, (2.115) の式は,

$$p(\mathbf{x}) = \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}, \boldsymbol{\Lambda}^{-1}) \quad (2.113)$$

と

$$p(\mathbf{y} | \mathbf{x}) = \mathcal{N}(\mathbf{y} | \mathbf{A}\mathbf{x} + \mathbf{b}, \mathbf{L}^{-1}) \quad (2.114)$$

が与えられた際の周辺分布だったことに注意して, (2.113) から (2.115) について,

$$\mathbf{y} \rightarrow t, \quad \mathbf{x} \rightarrow \mathbf{w}, \quad \boldsymbol{\mu} \rightarrow \mathbf{m}_N, \quad \boldsymbol{\Lambda}^{-1} \rightarrow \mathbf{S}_N, \quad \mathbf{A} \rightarrow \phi(\mathbf{x})^T, \quad \mathbf{L}^{-1} \rightarrow \beta^{-1}$$

と置き換えると, (3.57) を評価することができる.

したがって, (2.115) にそれぞれを代入すると,

$$p(t \mid \mathbf{x}, \mathbf{t}, \alpha, \beta) = \mathcal{N}(t \mid \mathbf{m}_N^T \phi(\mathbf{x}), \sigma_N^2(\mathbf{x})) \quad (3.58)$$

と求まる. ここで, 入力に依存する分散は,

$$\sigma_N^2(\mathbf{x}) = \frac{1}{\beta} + \phi(\mathbf{x})^T \mathbf{S}_N \phi(\mathbf{x}) \quad (3.59)$$

である.

問題 3.15

線形基底関数からなる回帰モデルの超パラメータ  $\alpha, \beta$  をエビデンス枠組みを用いて決定する場合を考える.(3.82) で定義される関数  $E(m_N)$  が関係式  $2E(m_N) = N$  を満たすことを示せ

解答 3.15

エビデンス関数を最大にする  $\alpha$  と  $\beta$  は (3.92) 式と (3.95) 式より

$$\begin{cases} \alpha = \frac{\gamma}{m_N^T m_N} \\ \beta = (N - \gamma) \{ \sum_{n=1}^N \{ t_n - m_N^T \phi(x_n) \}^2 \}^{-1} \end{cases}$$

これらを (3.82) 式に代入すると

$$\begin{aligned} E(m_N) &= \frac{\beta}{2} \|t - \phi m_N\|^2 + \frac{\alpha}{2} m_N^T m_N \\ &= \frac{N - \gamma}{2} + \frac{\gamma}{2} \\ &= \frac{N}{2} \end{aligned}$$

なお

$$\|t - \phi m_N\|^2 = \sum_{n=1}^N (t_n - m_N^T \phi(x_n))^2$$

である。